



황화인

AI Engineer · Agent & Harness Engineering

immortal@gmail.com · 010-7517-9503

GitHub ↗ Blog ↗ Portfolio ↗ LinkedIn ↗ YouTube ↗



상세 포트폴리오 ↗

AI Agent를 구현하고, 하네스로 실행을 통제하며, 결과를 검증합니다.

DB 설계 → Agent-Hybrid RAG → 정량 평가·추적 → 최적화까지 직접 수행했습니다.

- 9개 AI Agent × 23개 데이터 소스 분량성 보고서 · 약 30분 생성
도메인 전문가 자문 · 부스전시 · 중앙일보·한국경제 보도자료
- 기억하는 게임 NPC · 응답 8.5초→2~3초 · 페르소나 71.6%→86.7%
“AI를 제거하면 핵심 재미가 사라진다”는 심사평 → 언리얼×AI 프로젝트 최종 우승
- 회사 개발 자동화 하네스 비교 평가 253회 완료 → 오픈소스 SENTINEL
A/C: 최대 CRAP 평균 91.4%↓ · mutation 평균 +45.7%p | 플러그인 3언어·2Agent
- Copilot 평가·개선 하네스 · 100개 시나리오 · 17개 지표
95개 시나리오의 277개 결과 조건 구축 · 배포 미시도 22건 오판 수정 · Hook 실행 통제
- AI 하네스 기반 Q&A Full-stack 단독 구축
6개 화면·12개 API · 권한·동시성·보상 삭제 · 용량 초과 재현의 잔여 객체 증가 1→0개
- 협회 사무국장 추천서 · 전체 기수 유일한 운영총괄 공식 추천서
동료 투표 4회 중 2회 최다 득표 (1회차 · 4회차)

TECH STACK

AI Agent·평가 · LangGraph · LangChain · ReAct · Reflection · Hybrid RAG · DeepEval · RAGAS · Langfuse · OpenAI · Claude · Gemini · Grok

하네스·코드 품질 · Harness Engineering · HITL · CRAP · Mutation Testing · MCP · Claude Code CLI · GitHub Actions · Slack API

서비스 개발 · Python · TypeScript · FastAPI · Next.js · PostgreSQL · Redis · Supabase · MinIO · Keycloak · Docker · Streamlit

검색·ML · pgvector · PGroonga · BM25 · QLoRA · LoRA · PyTorch · YOLOv8 · ArcFace

회사 경력

실제 기능 구현 · 실행 통제 · 평가

베스핀글로벌 GenAI Engineer Intern

2026.06 - 2026.09

Helpnow Foundry Copilot 평가·개선 하네스 ↗

100개 시나리오 · 277개 조건

2026.07 · 약 2주 · 단독 설계·구현 | Enterprise Agent Evaluation · Harness Engineering

문제: 자연어로 업무 자동화를 만드는 Copilot의 기능·화면 오류와 고객 불편이 문서화되지 않아 개선 기준이 없었다. 점검 중 화면의 성공 표시와 메일·시트의 실제 결과가 어긋나고 기존 평가도 생성만 확인하는 문제를 발견했다.

- **실결과 검증:** 100개 시나리오 중 결과 검증 대상 95개에 277개 조건 정의. 외부 API·실행 출력·워크플로우 상태를 조회하고, Gmail은 실행 시각·수신자, Sheets-문서는 자료 ID로 이번 실행 결과를 확인.
- **17개 평가 지표:** 생성·배포·실행·설정·연결·실결과·내부 코드 노출을 코드와 DB의 고정 규칙으로 판정. 필수 검사는 모두 통과해야 하며, LLM Judge의 가독성·화면 일치·요청 충족·선택지 점수와 비용 지표는 참고로 분리.
- **Hook 실행 통제:** SessionStart로 최신 기준·실패 기록 제공. PreToolUse로 고정 시험지 변경·직접 서버 제어 명령 패턴을 중단하고, 테이블·컬럼 삭제 코드가 추가된 마이그레이션의 커밋을 차단.
- **UX-HITL:** 승인 카드의 내부 번호(unknown)를 작업 목적 설명으로 변경. 필수값은 입력 카드로 받아 반영·재검사하고, 구현 방식은 사용자 선택 후 진행. 수정 의견을 다음 작업에 전달하며 전송 실패 시 입력 복구.
- **기존 문맥 보존:** 워크플로우 조회 결과의 8,000토큰 제한을 제거해 큰 자동화의 문맥 전달을 보완. Gmail→Slack 수정 요청에 따른 대상 블록·연결선 변경을 화면에서 확인.

결과: 반복 시험지·17개 지표·실패 근거로 수정 전후를 비교할 기준을 마련했다. 배포 미시도 22건을 통과로 집계하던 오류를 바로 잡고, 계획상 연결 대신 DB에 저장된 실제 연결·설정을 검사했다.

Helpnow Foundry Q&A 게시판 Full-stack 구축 ↗

Full-stack 단독 구축

2026.08 · 약 2주 · 정책 협의 후 단독 설계·구현 | 화면 6개 · API 12개 · 테이블 3종

Next.js · FastAPI · PostgreSQL · MinIO · 기존 Keycloak 인증·공통 UI 활용

문제: 고객은 다른 고객의 문의·답변을 볼 수 없었고, 문의가 버그 신고 창구와 Google Chat에 흩어져 같은 질문에 반복 대응해야 했다. 비밀글 접근·중복 답변·첨부 실패를 일관되게 처리해야 했다.

- **문의·답변 흐름:** 공개 문의 검색과 회원 등록·상태 확인, 관리자 답변 등록·변경을 화면·API로 연결.
- **권한·동시성:** 비밀글과 그 첨부은 작성자·관리자만 서버에서 열람하도록 검사했다. 활성 답변에 DB UNIQUE 제약을 적용해 동시 요청에도 문의당 최대 1개를 유지했다.
- **원문 보존·XSS 대응:** 저장 전 태그 제거를 없애 <TypeError> 같은 오류 메시지를 보존하고, React JSX 문자열 출력으로 HTML 대신 텍스트로 표시.
- **파일·DB 실패 처리:** 모든 첨부은 먼저 검사하고 업로드·DB 커밋 실패 시 요청 파일을 보상 삭제. 삭제에 실패한 객체 키는 로그에 남김.
- **파일 수명주기:** 삭제된 첨부은 기본 30일 보관 후 정리하고 파일 삭제 성공 시에만 DB에 반영해 실패 건은 재시도.
- **개발 하네스:** 요구사항→기능 문서→Jira 완료 조건→사람 승인→구현·검증을 연결. SessionStart·PreToolUse·Stop으로 최신 규칙 전달·커밋 통제·잔여 작업 기록; 화면·API·로그와 Playwright·Serena로 확인.

결과: 1:1 게시판 개설 완료. 모든 요구사항 반영완료. 공개 문의·기존 답변 검색과 답변 대기 처리 기능을 완성했다. 정상 파일 뒤에 5MB 초과 파일을 넣은 실패 재현에서 MinIO 잔여 객체 증가량을 **1개→0개**로 줄였다.

개발 자동화 하네스 비교 평가 ↗

3단계 · 253회 완료

2026.08 - 09 · 회사 업무 | 실험 설계·환경 격리·실행 자동화·분석·보고서 단독 담당

문제: Jira 버그 자동 수정에 Prime Agent를 쓸지 판단해야 했지만, 단독 실행만으로는 다른 하네스와 비교할 근거가 없었다. 평가 과정에서 Agent의 조기 완료 선언·회귀·복잡한 수정 코드 때문에 기능과 품질을 따로 판정할 필요가 드러났다.

- **실험 규모:** 261회 계획·253회 완료. 1차 11조합·99회, 2차 GLM-5.2 고정 100회(공통 84회 분석), 3차 모델·하네스 고정 품질 조건 54회.
- **독립 채점:** 실제 결함 3건을 Git worktree 기반 작업 사본에서 실행하고 정답·사용자 설정 접근을 차단. 숨긴 정답·기존 테스트로 기능·회귀·거짓완료를 판정한 뒤 정답 테스트를 제외해 최종 품질을 재측정.
- **품질과 기능 분리:** CRAP(분기 복잡도·테스트 실행 범위)은 코드 위험도, mutation(인위적 코드 변경 검출률)은 테스트 검출력으로 측정. 기능 해결·시간·사용량과 별도 분석.

54회 중 A/C 비교	A → C	측정 실행 수
실행별 최대 CRAP의 평균 ↓	76.08 → 6.56 (-91.4%)	A 9회 / C 9회
mutation 평균 ↑	51.7% → 97.4% (+45.7%p)	A 8회 / C 9회

결과: 격리된 1·2·3차 실험 253회를 보고서 3건으로 정리하며, 품질 점수 개선이 기능 해결을 보장하지 않음을 확인했다. 실험의 CRAP·mutation 검사 절차를 3개 언어·2개 Agent에서 재사용할 수 있도록 오픈소스 SENTINEL을 단독 개발·공개했다.

AI Agent · 오픈소스

검색 · 기억 · 관측 · 품질 검사

SENTINEL · CRAP·mutation 품질 검사 플러그인 ↗

오픈소스 · 3개 언어

2026.09 · 회사 실험을 바탕으로 단독 개발·공개 | Python · TypeScript · Java / Claude Code · Codex

문제: 코딩 Agent의 완료 보고만으로는 결함 해결 뒤 남은 코드 위험과 테스트 검출률을 알 수 없다. 회사 실험에서 사용한 품질 검사를 여러 언어·Agent에서 반복하려면 서로 다른 도구와 결과 형식을 한 절차로 묶어야 했다.

- **검사 통합:** 언어별 도구를 임시 사본에서 실행해 CRAP·mutation을 측정하고 위치·점수·미달 이유를 공통 JSON으로 반환.
- **품질 판정:** 기본 기준 **CRAP≤8 · mutation≥90%**, 기존 프로젝트 기준 유지. 통과·미달·대상 없음·실행 오류를 분리해 미검사를 통과로 표시하지 않음.
- **수정·재검사:** SENTINEL이 진단하면 Agent가 코드·테스트를 고치고 최초 기준·범위로 재검사. 점수 확인만 요청하면 수정 없이 종료.

결과: **3개 언어 · 2개 Agent**의 검사·진단·재검사 절차 통합. MIT 라이선스와 한국어·영어 설치·사용 문서 공개.

CRAP · mutation testing · mutmut · StrykerJS · mutate4java

[공개 저장소·설치 안내 ↗](#)

ALL_FOR_ONE · 분양성 검토 보고서 Agent ↗

부스전시 · 보도자료

2025.10 - 11 · 3명→2명 팀·팀장 | 아키텍처·Agent 4종·평가·추적·도메인 자문 담당
전체 시스템: 9개 Agent x 23개 데이터 소스 → 보고서·출처 데이터 생성

문제: 분양성 검토 보고서는 수작업으로 통상 1~2주가 걸렸고, 기존 자동 보고서는 데이터를 나열해도 공급·수요·정책이 분양 가능성과 가격에 미치는 영향을 설명하기 어려웠다. 근거와 원본 출처를 함께 제공하는 보고서가 필요했다.

- **Agent 설계:** 7개 분석 Agent 구조를 설계하고 정책·입지·주변시장·보고서 Agent를 구현. 초안→Pydantic 검사→부족한 섹션 재검색·수정 분기 설계.
- **ReAct 필요성 검증:** 추가 추론·자기검증을 전면 적용(79.04%)→제거(76.91%)→선택 적용·출력 정리(**83.52%**)로 3단계 비교. 단순 정보 추출에서는 제거하고 복잡한 분석에 유지하는 구성을 채택.
- **Hybrid RAG:** pgvector 의미 검색과 한국어 BM25를 결합하고 현업 보고서·전문가 자문으로 분석 항목과 출처 확인을 설계.
- **관측·토론 최적화:** Langfuse로 LLM 호출 30곳 이상의 토큰·비용을 추적. 보고서 분할·중복정보 제거로 입력 **28만→8만 토큰**.
- **정량 평가:** DeepEval 9종·RAGAS 3종으로 분석·출처 실패를 수정해 종합평가 **78.65%→85.38%**.

결과: 약 **30분**에 최종 보고서·출처 PDF와 원본 CSV **17종**을 생성·전달. 프로젝트 E2E 평가 **9/9 통과**, 정책 분석 **64.67→92%**, 출처 평가 **30→80%**. 저장된 출력의 재평가 대기는 **38분→0.13초**.

대외 성과: 협회 전문가 자문을 설계에 반영하고 제10회 부동산산업의날에서 부스 시연. [중앙일보](#) ↗ · [한국경제 보도자료](#) ↗ 게재.

LangGraph · PostgreSQL · pgvector · DeepEval · Langfuse

[GitHub](#) ↗ · [상세 기록](#) ↗

MEMORIA_LABYRINTH · 기억하는 대화형 NPC ↗

최종 우승 · 1위

2025.11 - 2026.01 · 6명 팀·팀장 | 사용자↔NPC·NPC↔NPC Agent, DB, 평가·추적, TTS, 발표

문제: 서브컬처 게임의 고정 선택지는 대화 자유도를, 로그라이크의 반복 패턴은 재플레이의 신선함을 제한했다. AI를 핵심 재미로 삼는 팀 프로젝트에서 플레이어와 자유롭게 대화하고 취향·지난 대화를 기억하는 NPC가 필요했다.

- **SPO 장기기억:** Mem0의 화자 혼동을 해결하기 위해 대화를 주어·서술어·목적어 형태의 사실로 추출·저장.
- **기억 검색:** 최근성·중요도·관련성·키워드로 기억을 검색해 “과일” 질문에 과거 “사과” 선호를 회상.
- **기억 갱신·문맥:** 중복·취향 변경 시 이전 기억의 유효 종료 시각을 기록하고 조건부 요약·중요도 정리로 맥락 유지.
- **상태·대화 정합성:** 호감도·정신 상태·기억 해금에 따라 대사를 조정. NPC 간 대화 개입 시 체크포인트·장기기억·Redis의 이후 대화를 무효화.
- **평가·관측:** Langfuse 11곳과 DeepEval 4종·CI로 평가. 의도별 선택 검색·기억 처리 백그라운드 전환으로 지연 축소.

결과: 기억 검색 **3.5→1초**, 대화 응답 **8.5→2~3초**, 4캐릭터×6유형 페르소나 평가 **71.60→86.67%**. 취향 변경 후 회상과 기억 해금 후 3회 연속 꼬리질문의 맥락 정합성을 확인.

Wanted POTENUP 언리얼×AI 융합 프로젝트 최우수상(전체 1위). 단계별 평가 후 최종 기업 심사에서 선정. 심사평: “AI를 제거하면 핵심 재미가 사라진다.”

LangGraph · Redis · DeepEval · Langfuse · Docker

[GitHub](#) ↗ · [수상·협업 기록](#) ↗

추가 기술 경험 · 협업과 이력

개발 도구 · 모델 학습 · 도메인 경험

THE_FORGE · 멀티에이전트 개발 하네스 ↗

3-Agent · HITL · 재개

2026.04 · 단독 개발 | 계획 → 코드 생성 → 평가를 연결하는 Harness 오케스트레이터

문제: 하나의 코딩 AI 세션이 계획·구현·자체 평가를 계속 맡으면 긴 작업의 문맥이 누적되고 스스로 만든 결함을 놓치기 쉽다. 사람 승인·중단 후 재개 절차도 필요했다.

- **실행 흐름:** Claude Code CLI 하위 프로세스로 Planner·Generator·Evaluator 세션을 분리하고 문서로 기준·결과 전달. Evaluator가 완료 조건과 커밋 비교.
- **HITL·중단:** Slack·Telegram에서 승인·수정·종료를 받고 시간·스프린트 수·연속 실패 횟수로 자동 중단.
- **재개·관측:** 9단계 체크포인트에서 재개하고 Langfuse로 세션별 토큰·비용 추적.

결과: 독립 평가·사람 승인·중단·재개가 연결된 하네스 구현.

Claude Code CLI · Slack Socket Mode · HITL · Langfuse

[GitHub](#) ↗

도구 연동 · 파인튜닝 · 멀티모달

부동산 입지 분석 MCP 서버

MCP 해커톤 · 공개 데모

2025.11 · 단독 개발

목표: 입지 검토 Agent가 주소 주변 시설을 같은 형식으로 조회하도록 했다. 주소·반경을 받아 Kakao Local API에서 교육·교통 등 5개 범주의 시설·거리 정보를 조회하는 FastMCP·Gradio 도구를 단독 구현하고 Hugging Face Spaces에 공개 데모를 배포했다.

[GitHub](#) ↗ · [데모](#) ↗

보이스피싱 탐지 · PLM/LLM

QLoRA 파인튜닝

2025.09 · 3명 팀·팀장

문제: 사후 신고·발신번호 목록만으로는 통화 중 위험을 포착하기 어려웠다.

KoELECTRA의 빠른 분류와 Gemma-2B QLoRA 맥락 분석을 비동기로 결합하고, 불안정한 LLM 출력의 4단계 복구와 YOLOv8-ArcFace 안면 확인을 구현. 검증 대화 16건에서 PLM **16/16건**, LLM **11/16건** 정답. [GitHub](#) ↗

표정·음성·텍스트 멀티모달 분석

17만 장 전처리

2025.08 · 이미지 AI 담당

문제: 설문·단일 신호의 한계를 보완하려는 팀 과제에서 담당 이미지 모델이 얼굴보다 배경에 반응했다.

Grad-CAM 진단 후 350GB·17만 장에 얼굴 검출·크롭·캐시를 적용하고 ResNet·ConvNeXt를 파인튜닝. 검증 F1은 **ResNet 원본 0.7009→얼굴 크롭 0.7535→ConvNeXt 0.7562**, 재학습 전처리 **5~6시간→수초**. 음성·텍스트 결합은 팀 구현. [GitHub](#) ↗

교육 · 수상

Wanted POTENUP AI Agent 개발자 과정

2025.07 - 2026.01

6개월 수료 · 수강생 대표 · 수료식 축하 대표

도메인 AI Agent의 모든 것 · Fast Campus

2026.04 - 05

보안·금융 도메인의 Agent 아키텍처와 가드레일 설계 과정 수료.

POTENUP 엔리얼×AI 융합 프로젝트 최우수상(1위) · 2026.01

협업 · 추천

한국부동산마케팅협회 조준환 사무국장

분양성 검토 프로젝트의 도메인 자문·검증자로 협업 후 공식 추천서 작성. [추천서](#) ↗

윈티랩 POTENUP 김아름 운영총괄

전체 기수 중 유일한 운영총괄 공식 추천서 · 기술 습득·프로젝트 성과·협업 평가. [추천서](#) ↗

동료 투표 4회 중 2회 최다 득표.

이전 경력

한국자산매입 · 부동산 마케팅 기획

2024.05 - 2025.02

광고 대량 등록·데이터 분석으로 주간 노출 5만→300만, 클릭수 8배 성장. [성과 기록](#) ↗

(주)더제이엠 · 부동산 분양상담

2023.12 - 2024.03

200명 규모 현장 조직에서 최초 상가 계약 달성.

유로메디케어 · 의료기기 기술영업·기획

2021.09 - 2023.03

주요 6개 대학병원 영업 허가 확보, 의료진·환자 대상 기술 설명과 교육 담당.

학력

강서대학교 음악학과 · 편입·졸업

2018.03 - 2020.02

4.27/4.5 · 수석 졸업 · 성적우수 장학금

원광대학교 생물환경화학학과

2012.03 - 2014.02

4.42/4.5 · 과수석 2회 · 성적우수 장학금